

INFORME DETALLADO

■■■■■

■■

■■■■■■■■■■■■■■■■■■■■

Fecha: 2026-08-24

1. RESUMEN EJECUTIVO

Este documento describe el funcionamiento, estado actual, riesgos y próximos pasos del proyecto ``crawler_finrural`` (Prospector Externo Multi-Fuente).

- Propósito: automatizar la prospección y normalización de documentos públicos (reportes financieros, boletines, archivos comprimidos) desde fuentes como FINRURAL y BBV.
- Estado: código modular con pruebas automatizadas. Integraciones opt-in: Wayback, crt.sh, AsyncIO-fetcher y Playwright+OCR (branch ``feature/playwright-ocr``).

2. FLUJO PRINCIPAL Y COMPONENTES

1. Configuración fuente (YAML)

- Define semillas, reglas de inclusión/exclusión, límites y flags opt-in.

2. Discovery

- Seeds locales
- Opt-in: Wayback CDX (historial), crt.sh/Omnisint (subdominios), sitemaps, búsqueda dorking (opcional)

3. Fetcher

- ``fetcher.py``: cliente HTTP sincrónico con respeto a ``robots.txt``, rate limits y manejo de descargas.
- ``async_fetcher.py``: cliente opcional basado en ``httpx.AsyncClient`` con wrappers sync para compatibilidad.

4. Extractor & Archive

- Descarga archivos (PDF, XLSX, CSV, ZIP/TAR).
- Si es un contenedor, descomprime en memoria y genera recursos individuales.

5. Canonicalizer

- Limpia parámetros irrelevantes de URL, genera ``resource_key`` estable.

6. Reducción y Export

- Deduplicación por hash SHA-256
- Exporta contratos JSON en 3 vistas: Standard, Tree y Compact.

7. Opt-in avanzado: Render + OCR

- ``renderer_playwright.py``: captura PNG/PDF de páginas dinámicas usando Playwright (opt-in).
- ``ocr_adapter.py``: ejecuta OCR local con ``pytesseract`` sobre imágenes generadas.

3. ESTADO DE PRUEBAS Y VALIDACIÓN

- Suite de tests: ``python -m pytest -q``

■■■■■

■■

■■■■■■■■■■■■■■■■■■■■

■■■■■

■■

■■■■■■■■■■■■■■■■■■■■` -> `18 passed` en el entorno de desarrollo.

- Script de chequeo rápido: ``scripts/check_urls.py``

■■■■■

■■

■■■■■■■■■■■■■■■■■■■■ -> valida seeds, Wayback, crt.sh y HEADs.

4. INSTALACIÓN F3N Y DEMO LOCAL (PASO A PASO)

1) Crear entorno y dependencias mediante:

```
``bash
python -m venv .venv
source .venv/bin/activate # o .venv\Scripts\activate en Windows
python -m pip install -e .
```

2) (Opcional) Instalar render+OCR localmente:

```
``bash
python -m pip install playwright pillow pytesseract reportlab
python -m playwright install # descarga navegadores
```

3) Ejecutar tests reales:

```
``bash
python -m pytest -q
```

4) Ejecutar chequeo de seeds/servicios:

```
``bash
python scripts/check_urls.py
```

5. RIESGOS Y MITIGACIONES

- Dependencia de servicios públicos: `web.archive.org` y `crt.sh` son inestables -> mitigación: retries, backoff, caché local (`external\_cache.py`) y fallbacks (Omnisint, archive.org availability API).
- Playwright y Tesseract requieren binarios locales y pueden aumentar la complejidad en CI -> mitigación: mantener opt-in y crear job CI separado con runners que soporten navegadores.
- Datos escaneados sin texto: OCR calidad variable -> mitigación: agregar preprocesado de imágenes (binarización, DPI), y reglas de verificación de confianza.

6. MÉTRICAS Y OBSERVABILIDAD RECOMENDADAS

- Contadores: páginas procesadas, recursos descargados, resources accepted/rejected
- Timings: latencia de Wayback/crt.sh, tiempos de render/OCR
- Errores: tasas de timeout y códigos 5xx de servicios externos

7. ROADMAP PROPUESTO (PRIORIZADO)

1. Finalizar y validar Playwright+OCR con pruebas E2E (opt-in).
2. Añadir CI: fast-tests (unit), integration-tests (no Playwright), e2e-playwright (opt-in, manual/runners especializados).
3. Implementar cache compartida (Redis) para despliegues distribuidos.
4. Añadir proveedores pagados como fallback (SecurityTrails) para subdomains.
5. Métricas + alertas (Prometheus/Grafana).

8. ENTREGABLES ADJUNTOS

- `docs/stakeholder\_detailed.md`

■■■■■

■■

██████████████████ - este documento.

- `docs/stakeholder\_report.pdf` - versión PDF generada y lista para presentar (si se creó).

Si quieres que genere una versión en PPTX para la reunión, o que adapte la PDF con tu logo corporativo y notas del presentador, lo hago a continuación.